

# Статистические тесты

Аббревиатура **KPI** (key performance indicators) переводится на русский язык как «ключевые показатели эффективности», или «ключевые индикаторы выполнения». Иногда встречается аббревиатура КПЭ — это одно и то же.

KPI — это показатели достижения цели: количество продаж, сделанных звонков, приведенных клиентов и т.д.

👉 В работе аналитика обычно встречаются два типа KPI:

— численные KPI (обычно средние). Например: средний чек, число покупок пользователя, длительность пользовательской сессии, время ответа службы поддержки, объем горючего при заправке автомобилей на заправке, время закрытия объявлений о продаже квартир и другие;

— процентные KPI (они же вероятности и пропорции). Например: вероятность регистрации пользователей, процент покупателей (**конверсия** в покупку), пропорция удержания пользователей к определенному дню после регистрации, доля пользователей перешедших по рекламному объявлению.

**Конверсия** — это процент посетителей сайта, которые совершили определённое действие, например: зарегистрировали профиль или заказали товар.

🔍 Исследуем два KPI:

- средний чек индивидуального пользователя - общая сумма покупок, совершенных пользователем после регистрации;
- вероятность конверсии пользователя в покупку - процент новых пользователей, которые стали покупателями.

При анализе KPI мы можем проводить два вида исследований:

- сравнивать KPI с фиксированным порогом;
- проверять отличие значений KPI между двумя или более группами (так работают A/B-тесты).

Есть методики, которые позволяют провести анализ KPI и получить статистически-аргументированные выводы с заданной вероятностью допустить ошибку - это **статистические тесты**.


Прежде, чем переходить к статистическим тестам, давайте поговорим о двух концепциях, важных для понимания тестирования:

🔍 Генеральная совокупность — совокупность всех возможных наблюдений, относительно которых предполагается делать выводы при постановке гипотезы.

🔍 Выборка — часть генеральной совокупности, которая была охвачена сбором данных.

Генеральная совокупность практически никогда недостижима, поэтому на практике аналитики всегда работают с выборками. Поэтому наши наблюдения приблизительны, они могут содержать ошибки.

Статистические тесты - это математические методы, которые по отдельным выборкам (одной или двум) помогают судить о параметрах генеральных совокупностей.



🔍 Статистическая гипотеза — это предположение о распределении переменной, которое может быть верным или нет.

Статистическая гипотеза состоит из двух гипотез — **нулевой** и **альтернативной**.

Нулевая гипотеза указывает на отсутствие различий в сравниваемых группах.

Альтернативная гипотеза, наоборот, утверждает, что различия есть.

👉 Несколько примеров нулевых гипотез:

1. Лекарство не влияет на уровень холестерина в крови. (То есть, уровень холестерина у пациентов, принимающих лекарство, такой же, как у тех, кто его не принимает.)
2. Увеличение минимальной заработной платы не влияет на уровень безработицы. (То есть, уровень безработицы остается таким же, независимо от изменения минимальной заработной платы.)
3. Новая методика обучения не влияет на успеваемость студентов. (То есть, успеваемость студентов, обучающихся по новой методике, такая же, как у студентов, обучающихся по традиционной методике.)
4. Уровень загрязнения воды не влияет на количество рыбы в реке. (То есть, количество рыбы в реке остается неизменным, независимо от уровня загрязнения.)

Альтернативная гипотеза формулируется так, чтобы противоречить нулевой. Например:

*Нулевая гипотеза* — при публикации художественной книги издателям безразличен гендер автора.

*Альтернативная гипотеза* — при публикации художественной книги издатели предпочитают либо авторов-мужчин, либо авторов-женщин.

Когда мы проводим статистический тест, то либо отвергнем нулевую гипотезу, либо нет. Например:

— Мы не можем сказать, что издателям безразличен гендер автора (отвергли нулевую гипотезу).

— Издателям безразличен гендер автора (приняли нулевую гипотезу).


Мы делаем выводы **только о нулевой гипотезе**. То есть наша задача — проверить нулевую гипотезу, а не подтвердить альтернативную.

 Тесты бывают параметрические и непараметрические. Если мы уверены, что данные *распределены нормально*, — можем проводить параметрические тесты. Если нет — то непараметрические.

**Закон нормального распределения** — это статистический закон, который описывает большие наборы данных — например, 10 тысяч бросков кубика.

Закон говорит: есть среднее значение, оно встречается чаще всего; чем дальше от среднего — тем реже оно встречается.

Закон нормального распределения работает почти во всех областях, где происходят случайные события: от игральных костей до макроэкономических процессов.



В отличие от параметрических тестов – непараметрические тесты позволяют исследовать данные без каких-либо допущений о характере распределения переменных. Это означает, что они не проверяют ни один из параметров выборок (например, среднее, медиану или дисперсию). В непараметрических критериях обрабатываются не значения переменных, а их ранги или частоты. Ранг – это число, определяющее положение

наблюдения в выборке отсортированных данных. Непараметрические тесты можно применять при наличии в данных «выбросов» и неоднородных данных.

### Пример

👉Представьте, что вы бросаете монету. Нулевая гипотеза — это предположение, что монета честная, то есть вероятность получить орел или решку равна 50%.

Теперь, если вы бросаете монету много раз и получаете, скажем, 8 орлов подряд, это может показаться странным. Одним из итогов теста является показатель ***p-value***. Буква "p" в данном контексте обозначает "probability". p-value — это значение, которое отражает вероятность получения наблюдаемых данных (или более экстремальных) при условии, что нулевая гипотеза верна.

В нашем случае p-value помогает нам понять, насколько это странно получить 8 орлов подряд.

Если p-значение маленькое (например, меньше 0.05), это значит, что получить 8 орлов подряд — очень маловероятно, если монета честная. В таком случае мы можем подумать, что, возможно, монета не честная, и стоит это проверить.

Если p-значение большое, это значит, что 8 орлов подряд — это не так уж и странно, и мы не можем утверждать, что монета не честная.

Таким образом, p-значение помогает нам решить, стоит ли сомневаться в нашем первоначальном предположении (нулевой гипотезе) или нет.


Это можно интерпретировать так:

Представьте, что вы живете в мире, где верна нулевая гипотеза: все монетки честные. У вас случается 8 орлов подряд. Если p-value меньше 0.05, то это говорит о том, что в вашей реальности с вами случилась какая-то аномалия: случилось очень маловероятное событие. Ну, либо вам нужно выйти за рамки своего мира и расширить свой кругозор 😊 и подумать об альтернативных вариантах, которые существуют

Что такое 0.05? О таком пороге договорились статистики. Уровень значимости  $\alpha$  - это вероятность, с которой значение параметра не попадает в **доверительный интервал**. Еще это можно понимать так:  $\alpha$  - это вероятность, с которой мы ошибочно отвергаем нулевую гипотезу, когда она на самом деле верна. С уменьшением  $\alpha$  мы становимся более консервативными и боимся отвергать гипотезу (в медицине этот порог обычно ставят равным 0,01).

Уровень доверия  $\beta = 1 - \alpha$  - это вероятность того, что доверительный интервал накрывает значение параметра.

**Доверительный интервал** — интервал, в пределах которого с заданной вероятностью лежит параметр генеральной совокупности.



Если уровень значимости 0,05, то с 95% вероятностью наши значения попадают в доверительный интервал

⚡ Итак: если p-value больше заданного уровня значимости, то считаем, что нулевая гипотеза не отвергается (т.е. она верна). Если p-value меньше заданного уровня значимости, то считаем, что нулевая гипотеза отвергается (т.е. верна альтернативная гипотеза).

### Еще пример

👉 Давайте представим, что вы проводите эксперимент с растениями. Вы хотите узнать, влияет ли удобрение на рост растений.

1. **Нулевая гипотеза:** удобрение не влияет на рост растений. То есть, растения с удобрением и без удобрения вырастут примерно одинаково.
2. **Эксперимент:** вы сажаете две группы растений: одна группа получает удобрение, а другая — нет. После нескольких недель вы измеряете, насколько они выросли.
3. **Результаты:** вы обнаруживаете, что растения с удобрением выросли значительно выше, чем без него.

Теперь p-value поможет вам понять, насколько это различие значимо:

- Если p-value маленькое (например, меньше 0.05), это значит, что такое большое различие в росте между двумя группами маловероятно, если удобрение действительно не влияет на рост. В этом случае вы можете подумать, что удобрение действительно помогает растениям расти.
- Если p-value большое, это значит, что такое различие могло бы произойти и случайно, даже если удобрение не влияет на рост. В этом случае вы не можете с уверенностью сказать, что удобрение действительно помогает.

Важно подчеркнуть, что «не отвергаем» и «безоговорочно принимаем»  $H_0$  — разные вещи. Если мы не смогли найти весомый довод против основной гипотезы, то это вовсе не значит, что она верна. Возможно, это не так, но из-за каких-то причин (плохой критерий, неудачная выборка и т.д.) мы не смогли её отвергнуть. Надо помнить, что наша ключевая цель – найти весомые косвенные доказательства неверности  $H_0$  в пользу  $H_1$ , а если таковых не нашлось, то мы либо принимаем гипотезу на веру (куда деваться?), либо подбираем другие критерии в надежде её опровергнуть.

## T-test

T-тест используется для сравнения средних значений. Он показывает наличие различий между группами.

**Важно!** t-тест работает только со средними значениями.

С помощью t-теста можно анализировать разнообразные численные метрики. Например:

- средний чек;
- среднюю длину пользовательской сессии;
- среднее число покупок пользователя за период;
- средний уровень, достигнутый пользователем онлайн-игры;
- среднее количество запусков приложения.

Гипотезы для него формулируются вот так:

Для **одновыборочного** теста

**$H_0$**  (нулевая гипотеза): среднее равно заданному порогу;

**$H_1$**  (альтернативная гипотеза): среднее не равно заданному порогу.

Для **двухвыборочного** теста

**$H_0$**  (нулевая гипотеза): средние значения переменной в двух группах не отличаются значимо;

**$H_1$**  (альтернативная гипотеза): средние значения не равны (отличаются).

👉 Для проведения t-теста нужно, чтобы исходные данные имели **нормальное распределение**. Строго математически, это так, но для выборок размером больше 30-50-ти элементов t-тест можно применять для данных с любым типом распределения.

👉 Также необходимо, чтобы данные обладали **незначительными различиями в дисперсии** между двумя группами наблюдений. Это означает, что вариация (или разброс) значений в одной группе наблюдений не сильно отличается от вариации в другой группе.

В статистике **дисперсия** — это мера того, насколько значения в наборе данных разбросаны относительно среднего значения.

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n}$$

$s$  - СТАНДАРТНОЕ ОТКЛОНЕНИЕ

$n$  - КОЛ-ВО ЗНАЧЕНИЙ

$x_i$  - КАЖДОЕ ОТДЕЛЬНОЕ ЗНАЧЕНИЕ

$\bar{x}$  - СРЕДНЕЕ ЗНАЧЕНИЕ

ГРУППА А : 10, 12, 11, 13, 9

$$\bar{x} = \frac{10+12+11+13+9}{5} = 11$$

$$s^2 = \frac{(10-11)^2 + \dots + (9-11)^2}{5} = \underline{2}$$

ГРУППА В : 5, 15, 25, 35, 45

$$\bar{x} = 25$$

$$s^2 = \frac{(5-25)^2 + \dots + (45-25)^2}{5} = \underline{200}$$

👉 И переменная для оценки должна быть **непрерывна**

Непрерывные переменные могут иметь бесконечное количество значений между двумя любыми точками. Например:

Непрерывная переменная: Высота человека (может быть 170.5 см, 170.55 см, 170.555 см и так далее). Она может принимать любые значения в пределах определенного диапазона.

Дискретная переменная: Количество детей в семье (может быть 0, 1, 2, 3 и т.д., но не может быть 2.5 детей).

Чтобы проверить нормальность распределения, существует критерий Шапиро-Уилка

```
>>> shapiro(data) # из модуля scipy.stats
```

Для проверки равенства дисперсий используют критерий Левене

```
>>> levene(data_1, data_2)
```

Эти тесты также выдают p-value, на основе которого вы либо опровергаете гипотезу о нормальности распределения/равенстве дисперсий, либо нет.

## Z-тест

Давайте начнем с z-теста для пропорций. Он используется в ситуациях, когда нужно исследовать конверсию пользователей в какое-то событие. Например, с его помощью можно исследовать:

- процент регистрации пользователей;
- CTR (click through ratio) - долю пользователей, кликнувших рекламное объявление;
- конверсию в покупки.

Для одновыборочного z-теста гипотезы формируются вот так:

$H_0$  (нулевая гипотеза): доля целевых наблюдений равна заданному порогу;

$H_1$  (альтернативная гипотеза): доля целевых наблюдений не равна заданному порогу.

Теперь нам нужно сравнить доли пользователей, совершивших какое-то событие в двух группах. Для этого используется двухвыборочный z-тест для пропорций.

Гипотезы для него формируются вот так:

$H_0$  (нулевая гипотеза): доли целевых наблюдений в обеих группах одинаковые;

$H_1$  (альтернативная гипотеза): доли целевых наблюдений в двух группах отличаются.

В общем случае z-тест похож на t-тест. Для z-теста нам необходимо знать **стандартное отклонение генеральной совокупности**.

Нулевая гипотеза представляет собой предположение о том, что между исследуемыми переменными нет значимой разницы или связи. В контексте Z-теста, который часто используется для сравнения средних,  $H_0$  обычно утверждает, что разница между средним значением выборки и средним значением генеральной совокупности равна нулю или что средние значения двух сравниваемых групп равны.

Одновыборочный Z-тест — это статистический метод, используемый для сравнения среднего значения выборки с известным средним значением генеральной совокупности при известном стандартном отклонении генеральной совокупности. Тест помогает определить, есть ли статистически значимая разница между средним значением выборки и средним значением генеральной совокупности.

Двухвыборочный Z-тест применяется для сравнения средних значений двух независимых выборок, чтобы определить, есть ли между ними статистически значимые различия. Часто используют, когда известны стандартные отклонения генеральных совокупностей, и размеры обеих выборок достаточно велики.

### Выборы между Z-тестом и T-тестом

➡ Z-тест применяется, когда размер выборки больше 30. Благодаря **центральной предельной теореме**, распределение средних значений выборки приближается к нормальному распределению, что делает Z-тест приемлемым.

**Центральная предельная теорема** гласит, что сумма большого количества независимых случайных величин имеет распределение близкое к нормальному.

➡ T-тест используется при размере выборки меньше 30. При малых выборках распределение средних значений может сильно отличаться от нормального, что требует использования T-распределения.

- ➡ Z-тест требует, чтобы стандартное отклонение генеральной совокупности было известно.
- ➡ T-тест не требует знания стандартного отклонения генеральной совокупности, вместо этого используется стандартное отклонение выборки.
- ➡ Z-тест обычно используется для определения, отличается ли среднее значение выборки от известного среднего значения генеральной совокупности, или для сравнения средних двух различных генеральных совокупностей при известных стандартных отклонениях.
- ➡ T-тест применяется для сравнения средних значений двух групп, когда стандартное отклонение генеральной совокупности неизвестно.

## Тест Манна-Уитни

Этот тест часто используется вместо t-теста в ситуациях, когда в данных есть существенные выбросы, сдвигающие средние. Либо когда вы не знаете, как распределены ваши данные.

Тест Манна-Уитни - непараметрический. Это означает, что он не проверяет ни один из параметров выборок (например, среднее, медиану или дисперсию). Часто можно встретить утверждение, что тест Манна-Уитни тестирует различие медиан в выборках.

❗ На самом деле, Манн-Уитни не может проверить ничего, кроме равенства распределений. Этот критерий не подходит для сравнения средних или медиан.

Поэтому гипотезы для теста Манна-Уитни формулируются вот так:

*H0 (нулевая гипотеза):* данные двух выборок имеют одинаковое распределение/получены из одной генеральной совокупности;

*H1 (альтернативная гипотеза):* данные двух выборок имеют разное распределение/получены из разных генеральных совокупностей.

## Еще одна классификация

Существует еще один признак классификации статистических тестов:



👉 Двусторонние тесты;

👉 Односторонние тесты.

Для выбора односторонней или двусторонней альтернативы у тестов обычно есть специальный параметр. Например, `stats.ttest_ind(a, b, equal_var = False)` по умолчанию проводит двусторонний тест (`alternative = 'two-sided'`), но его можно провести и для односторонней альтернативы `stats.ttest_ind(a, b, equal_var = False, alternative = 'less')` или `stats.ttest_ind(a, b, equal_var = False, alternative = 'greater')` .

При двустороннем тесте мы проверяем гипотезу  $H_0: \beta = \beta_0$  (в частности,  $\beta = 0$ ), используя альтернативную гипотезу  $H_1: \beta \neq \beta_0$ .

При одностороннем тесте альтернативная гипотеза меняется на  $H_1: \beta > \beta_0$  и  $H_1: \beta < \beta_0$  в зависимости от того, какое влияние оказывает  $x$  на  $y$  (положительное или отрицательное).



## Что почитать:

- T-test и другие <https://education.yandex.ru/handbook/data-analysis/article/bazovye-statisticheskie-testy?ncrnd=41617>
- виды t-тестов и доверительный интервал <https://teach-in.ru/file/presentation/pdf/intelligence-data-analysis-with-R-M-12.pdf>
- Z-test: <https://habr.com/ru/companies/otus/articles/793678/>
- P-value <https://habr.com/ru/articles/653363/>
- Какой тест выбрать <https://habr.com/ru/companies/otus/articles/805961/>
- T-test <https://dzen.ru/a/Yq9pm5BSCjGHZPe1>
- Стандартное отклонение <https://habr.com/ru/companies/lanit/articles/799317/>
- В целом про статистические тесты <https://www.tidydata.ru/hypothesis>
- Boxplot <https://www.tidydata.ru/boxplot>
- Односторонние и двусторонние тесты [https://youtu.be/B9u\\_grPccUs?si=eBh2yEwa3ATETFVE](https://youtu.be/B9u_grPccUs?si=eBh2yEwa3ATETFVE)
- Для тех, кому хочется математики <https://youtu.be/o7WWb1xMQLQ?si=a7FgKUULt4hc7fSI>